

COMP8035041 - Big Data Analytics - Assignment II

Arsitektur Big Data untuk Prediksi Risiko Kredit pada Platform Peer-to-Peer Lending: Pendekatan Skoring Kredit Alternatif bagi Peminjam Tanpa Akses Perbankan



Emmanuel Daniel W

2702751271

DAFTAR ISI

DAFTAR ISI	2
DAFTAR GAMBAR	4
DAFTAR TABEL.....	5
1. BAB I PENDAHULUAN.....	6
1.1. Latar Belakang Masalah	6
1.2. Market and Business Drivers	7
1.3. Pemangku Kepentingan yang Terlibat	8
2. BAB II RANCANGAN SOLUSI BIG DATA	10
2.1. Metode Pengumpulan Data	10
2.2. Teknologi Penyimpanan Data	11
2.3. Processing Framework.....	11
3. BAB III TATA KELOLA IT	13
3.1. Security.....	13
3.2. Compliance	13
3.3. Data Privacy	14
3.4. Data Quality	14
4. BAB IV DATA	17
4.1. Deskripsi Data	17
4.2. Model Data.....	19
4.3. Dataset untuk Diolah Menggunakan Machine Learning	21
5. BAB V Machine Learning untuk Big Data.....	24
5.1. Data Preprocessing	24
5.2. Feature Engineering.....	25
5.3. Algoritma Machine Learning	26
5.4. Proses Pengembangan Model dengan dan tanpa Spark MLlib.....	28
5.5. Evaluasi Model	29
5.6. Analisis	33
6. BAB VI Graph Analytics.....	36

6.1.	Pengembangan <i>Graph</i>	36
6.2.	Analisis dan <i>Insight</i> yang Diperoleh.....	38

DAFTAR GAMBAR

Gambar 4.1. Pipeline Transformasi Data dari Raw Data hingga Input Machine Learning 20

DAFTAR TABEL

Tabel 4.1. Statistik Deskriptif Variabel Numerik pada Dataset Accepted Loans	17
Tabel 4.2. Distribusi Risiko Pinjaman Berdasarkan Grade	18
Tabel 4.3. Perbandingan Karakteristik Dataset Accepted dan Rejected	19

BAB I

PENDAHULUAN

1.1. Latar Belakang Masalah

Akses terhadap pembiayaan merupakan salah satu fondasi utama dalam mendorong pertumbuhan ekonomi, baik pada tingkat individu maupun korporasi. Namun demikian, hingga saat ini masih terdapat jutaan individu dan pelaku usaha yang mengalami kesulitan dalam memperoleh kredit dari lembaga keuangan formal. Keterbatasan akses ini menjadi permasalahan krusial karena dapat menghambat aktivitas ekonomi, inovasi, serta inklusi keuangan secara keseluruhan. Salah satu penyebab utama dari permasalahan tersebut adalah keterbatasan sistem penilaian kelayakan kredit (*credit scoring*) konvensional yang telah digunakan selama beberapa dekade. Sistem seperti skor FICO (*Fair Isaac Corporation*) di Amerika Serikat, misalnya, hanya mempertimbangkan sejumlah variabel terbatas seperti riwayat pembayaran, jumlah utang, dan lama riwayat kredit. Pendekatan ini menghasilkan sebuah skor tunggal yang menjadi dasar utama dalam pengambilan keputusan kredit. Akibatnya, kelompok masyarakat yang belum memiliki riwayat kredit formal (*unbanked*), pelaku usaha kecil dengan arus kas yang tidak stabil, serta peminjam baru yang sebenarnya berpotensi layak secara finansial sering kali tidak dapat dinilai secara komprehensif dan akhirnya ditolak.

Seiring dengan perkembangan teknologi, muncul alternatif pembiayaan berbasis digital melalui platform *financial technology* (fintech), khususnya *peer-to-peer* (P2P) lending. Dalam satu dekade terakhir, platform ini berkembang pesat dan menjadi solusi bagi segmen peminjam yang tidak terlayani oleh perbankan tradisional. Namun, pertumbuhan tersebut juga diiringi dengan peningkatan volume data yang sangat besar. Setiap aktivitas pada platform, mulai dari pengajuan pinjaman, riwayat pembayaran, profil peminjam, hingga keputusan kredit, menghasilkan data dalam jumlah masif yang berpotensi menjadi sumber informasi yang bernilai tinggi. Meskipun demikian, besarnya volume dan kompleksitas data tersebut telah melampaui kemampuan metode analisis konvensional. Dalam perspektif Big Data, karakteristik data pada platform P2P lending memenuhi konsep 5V, yaitu *volume*, *velocity*, *variety*, *veracity*, dan *value*. Volume data mencapai puluhan juta record, *velocity* ditunjukkan oleh arus aplikasi pinjaman yang terus meningkat, *variety* terlihat dari kombinasi data terstruktur dan semi-terstruktur, *veracity*

berkaitan dengan kualitas data yang tidak selalu konsisten, dan value mencerminkan potensi manfaat besar dalam pengambilan keputusan kredit yang lebih akurat.

Dalam konteks tersebut, pendekatan *machine learning* berbasis Big Data menjadi solusi yang menjanjikan untuk mengatasi keterbatasan sistem *credit scoring* konvensional. Berbeda dengan pendekatan tradisional yang bersifat statis dan terbatas, *machine learning* mampu mengolah data dalam jumlah besar dengan banyak variabel secara simultan serta menangkap pola hubungan non-linear yang kompleks. Hal ini memungkinkan model menghasilkan prediksi risiko gagal bayar yang lebih akurat dan granular. Mengingat bahwa risiko kredit bersifat dinamis dan multidimensional yang melibatkan berbagai faktor seperti tujuan pinjaman, tenor, utilisasi kredit, dan profil peminjam sehingga pendekatan ini menjadi lebih relevan dibandingkan model linier sederhana. Berdasarkan latar belakang tersebut, permasalahan utama dalam penelitian ini adalah bagaimana meningkatkan akurasi sistem *credit scoring* pada platform P2P lending dengan memanfaatkan data historis dalam skala besar. Kompleksitas dan volume data yang tinggi menuntut pendekatan Big Data yang mampu mengelola dan menganalisis data secara efisien. Selain itu, hubungan antar variabel yang bersifat kompleks dan tidak linear memerlukan metode analitik yang lebih adaptif dibandingkan pendekatan konvensional.

Oleh karena itu, penelitian ini berfokus pada perancangan pipeline Big Data yang skalabel serta pengembangan model *machine learning* untuk memprediksi risiko gagal bayar (*is_default*) berdasarkan atribut profil peminjam dan karakteristik pinjaman. Dataset yang digunakan adalah Lending Club Loan Data periode 2007–2018 yang tersedia secara publik melalui Kaggle dengan lisensi CC0-1.0. Dataset ini mencakup sekitar 29,9 juta record aplikasi pinjaman, yang terdiri dari 2,26 juta pinjaman disetujui dengan 151 atribut serta 27,6 juta aplikasi ditolak dengan 9 atribut. Dengan memanfaatkan dataset berskala besar tersebut, penelitian ini diharapkan dapat menghasilkan sistem penilaian kredit yang lebih akurat, adaptif, dan inklusif dibandingkan pendekatan konvensional.

1.2. Market and Business Drivers

Pengembangan solusi Big Data untuk permasalahan *credit scoring* pada platform P2P lending didorong oleh sejumlah faktor pasar dan kebutuhan bisnis yang saling berkaitan. Faktor utama adalah pesatnya pertumbuhan industri fintech secara global, di mana platform P2P lending

menjadi alternatif pembiayaan yang signifikan bagi masyarakat sekaligus menarik investor dengan imbal hasil kompetitif. Pertumbuhan ini tercermin dari data Lending Club, di mana jumlah pinjaman meningkat dari 603 pinjaman (USD 4,79 juta) pada tahun 2007 menjadi 495.242 pinjaman (USD 7,94 miliar) pada tahun 2018. Lonjakan ini menghasilkan volume data yang sangat besar dan menuntut penggunaan pendekatan Big Data untuk pengelolaannya.

Seiring dengan peningkatan volume tersebut, risiko gagal bayar (*default*) juga meningkat. Tingkat gagal bayar sebesar 13,02%, bahkan mencapai 39,74% pada segmen berisiko tinggi, menunjukkan urgensi pengembangan sistem prediksi yang lebih akurat. Tekanan regulasi juga menjadi faktor penting, seperti Fair Credit Reporting Act (FCRA) dan Equal Credit Opportunity Act (ECOA), serta regulasi di Indonesia melalui Peraturan OJK tentang Layanan Pinjam Meminjam Uang Berbasis Teknologi Informasi. Regulasi ini menuntut sistem yang transparan, adil, dan akuntabel.

Selain itu, kemampuan mengolah data secara optimal menjadi keunggulan kompetitif bagi platform fintech. Hal ini juga berkaitan dengan agenda inklusi keuangan global yang didorong oleh World Bank dan International Finance Corporation (IFC). Didukung oleh kemajuan teknologi seperti Apache Spark dan Apache Hadoop, serta penurunan biaya cloud computing, implementasi solusi Big Data menjadi semakin feasible. Kombinasi faktor-faktor ini menciptakan urgensi sekaligus peluang dalam pengembangan sistem credit scoring berbasis Big Data.

1.3. Pemangku Kepentingan yang Terlibat

Pengembangan solusi Big Data untuk sistem credit scoring melibatkan berbagai pemangku kepentingan yang saling terhubung dalam satu ekosistem. Peminjam (*borrowers*) merupakan pihak yang paling terdampak karena kualitas sistem menentukan akses mereka terhadap pembiayaan. Sementara itu, investor (*lenders*) berperan sebagai penyedia modal dan sangat bergantung pada akurasi prediksi risiko. Platform seperti LendingClub berperan sebagai penghubung dan harus menyeimbangkan antara pertumbuhan bisnis dan kualitas kredit.

Regulator seperti Consumer Financial Protection Bureau (CFPB), U.S. Securities and Exchange Commission (SEC), dan Otoritas Jasa Keuangan (OJK) memastikan sistem berjalan secara adil dan transparan. Di sisi internal, tim data science dan engineering bertanggung jawab

atas implementasi teknis pipeline. Sementara itu, komunitas akademik berkontribusi dalam pengembangan metodologi dan validasi ilmiah. Secara keseluruhan, keberhasilan implementasi solusi Big Data tidak hanya bergantung pada teknologi, tetapi juga pada keseimbangan kepentingan seluruh stakeholder dalam ekosistem tersebut.

BAB II

RANCANGAN SOLUSI BIG DATA

2.1. Metode Pengumpulan Data

Dataset Lending Club memiliki skala yang sangat besar, yaitu lebih dari 29,9 juta baris yang terbagi dalam dua subset utama (*accepted* dan *rejected*). Oleh karena itu, proses data ingestion dirancang dengan mempertimbangkan keterbatasan memori pada lingkungan komputasi berbasis notebook serta efisiensi pemrosesan.

Pendekatan yang digunakan adalah batch ingestion dengan teknik chunking, yaitu memuat data secara bertahap dalam potongan berukuran 300.000 baris per iterasi menggunakan library Pandas. Strategi ini efektif dalam menghindari *memory overload*. Dataset *accepted* ($\pm 2,26$ juta baris) dapat diproses dengan konsumsi memori sekitar 1,76 GB setelah dilakukan seleksi 26 kolom penting dari total 151 kolom. Sementara itu, dataset *rejected* ($\pm 27,6$ juta baris) membutuhkan sekitar 10 GB RAM. Optimasi utama dilakukan melalui teknik column pruning, yaitu hanya memuat kolom yang relevan sejak tahap ingestion. Pendekatan ini secara signifikan mengurangi beban memori dan mempercepat proses loading data.

Sumber data berasal dari dataset Lending Club dalam format terkompresi (.csv.gz) yang diperoleh dari Kaggle (lisensi CC0-1.0), dengan dua file utama:

- *accepted_2007_to_2018Q4.csv.gz* (375 MB)
- *rejected_2007_to_2018Q4.csv.gz* (244 MB)

Proses pengunduhan dilakukan menggunakan Kaggle API untuk memastikan *reproducibility*. Seluruh pipeline—mulai dari ingestion hingga modeling—diimplementasikan dalam lingkungan Google Colaboratory (Colab) berbasis Python, yang dipilih karena kemudahan akses, dukungan GPU/TPU, serta integrasi dengan Google Drive sebagai penyimpanan persisten.

Untuk skenario produksi, arsitektur ingestion ini dapat dikembangkan menggunakan Apache Kafka sebagai *message broker* dan Apache Flume untuk ingestion paralel. Namun, pada tahap prototype, pendekatan batch berbasis Pandas sudah memadai untuk kebutuhan analisis.

2.2. Teknologi Penyimpanan Data

Arsitektur penyimpanan data menggunakan pendekatan Data Lakehouse, yang menggabungkan fleksibilitas Data Lake dan efisiensi query Data Warehouse. Pada tahap prototype, arsitektur ini disederhanakan dengan menggunakan Google Drive sebagai *persistent storage*, menggantikan sistem distributed storage seperti HDFS atau cloud object storage.

Lapisan pertama adalah Raw Layer (Data Lake) yang menyimpan data mentah dalam format asli (.csv.gz) tanpa modifikasi. Tujuannya adalah menjaga *data lineage* serta memungkinkan proses *reprocessing* jika diperlukan. Pendekatan ini menggunakan prinsip schema-on-read, di mana skema diterapkan saat data diproses.

Lapisan kedua adalah Processed Layer (Curated Zone) yang menyimpan data hasil pembersihan dan transformasi dalam format kolomar Apache Parquet. Format ini dipilih karena kompresi tinggi (hingga 70–80% lebih kecil dari CSV) dan performa query lebih cepat karena *columnar read*. Dalam implementasi, file Parquet disimpan di Google Drive agar dapat digunakan kembali tanpa perlu mengulang proses cleaning yang mahal secara komputasi. Strategi optimasi yang diterapkan meliputi partitioning berdasarkan waktu (*issue_year*) untuk mempercepat query serta penyimpanan model dalam format *.pkl* sebagai bentuk sederhana *model registry*. Untuk deployment skala besar, arsitektur ini dapat dikembangkan menjadi:

- Raw Layer → Google Cloud Storage / Amazon S3
- Processed Layer → BigQuery / Apache Hive

Dengan demikian, desain yang dibuat tetap scalable dan siap di-migrasi ke production environment.

2.3. Processing Framework

Pemrosesan data dalam skala besar membutuhkan framework yang mampu menangani komputasi secara paralel dan efisien. Dalam arsitektur yang diusulkan, Apache Spark dipilih sebagai processing engine utama karena:

- Pemrosesan *in-memory* yang cepat

- Dukungan native terhadap format Parquet
- Ekosistem lengkap (Spark SQL dan MLlib)

Pada implementasi prototype, Spark digunakan melalui PySpark di Google Colab dalam mode *local single-node*. Artinya, Spark berjalan pada satu mesin virtual ($\pm 2-4$ vCPU) tanpa cluster terdistribusi. Meskipun demikian, pendekatan ini tetap memberikan keuntungan penting, yaitu pipeline sudah menggunakan Spark DataFrame API dan kode siap di-*scale* ke cluster tanpa perubahan besar

Pipeline pemrosesan yang dibangun bersifat modular dan *reproducible*, dengan tahapan:

1. Data ingestion (chunking)
2. Data cleaning
3. Feature engineering
4. Exploratory Data Analysis (EDA)
5. Model training (Scikit-learn)
6. Model evaluation

Setiap tahap diimplementasikan dalam Jupyter Notebook terpisah untuk memudahkan debugging dan *re-execution*.

Untuk orkestrasi workflow pada skala produksi, Apache Airflow direkomendasikan. Airflow memungkinkan pipeline didefinisikan sebagai Directed Acyclic Graph (DAG) sehingga proses dapat dijadwalkan, dimonitor, dan di-*retry* secara otomatis jika terjadi kegagalan. Integrasi antara Airflow, Spark, dan storage berbasis cloud akan menghasilkan pipeline Big Data yang *fully automated* dan scalable.

BAB III

TATA KELOLA IT

3.1. Security

Keamanan data merupakan aspek krusial dalam pengelolaan data keuangan, terutama karena dataset mengandung informasi sensitif terkait peminjam. Oleh karena itu, sistem dirancang dengan pendekatan multi-layered security yang mencakup enkripsi, kontrol akses, dan audit aktivitas. Enkripsi diterapkan baik pada data yang tersimpan (*at rest*) maupun saat ditransmisikan (*in transit*). Data yang disimpan dienkripsi menggunakan standar AES-256, sementara komunikasi antar komponen sistem diamankan dengan protokol TLS 1.3. Pengelolaan kunci dilakukan melalui layanan terpusat seperti AWS Key Management Service atau Google Cloud Key Management Service, yang mendukung rotasi kunci secara berkala untuk meminimalkan risiko kebocoran.

Selain itu, diterapkan mekanisme Role-Based Access Control (RBAC) untuk membatasi akses pengguna berdasarkan peran. Data analisis hanya diberikan akses terhadap data yang telah dianonimisasi, sedangkan akses ke data mentah dibatasi pada pihak yang memiliki kebutuhan operasional yang sah. Untuk memastikan akuntabilitas, sistem juga menerapkan audit trail yang mencatat seluruh aktivitas pengguna, termasuk akses, perubahan, dan penghapusan data. Log ini disimpan secara terpisah dan tidak dapat dimodifikasi, sehingga dapat digunakan untuk keperluan forensik jika terjadi insiden keamanan.

3.2. Compliance

Kepatuhan terhadap regulasi menjadi komponen penting dalam pengelolaan sistem credit scoring, mengingat dampaknya terhadap keputusan finansial dan hak konsumen. Di Amerika Serikat, regulasi seperti Fair Credit Reporting Act (FCRA) mengatur penggunaan data kredit serta mewajibkan transparansi dalam keputusan penolakan kredit. Selain itu, Equal Credit Opportunity Act (ECOA) melarang diskriminasi berdasarkan atribut seperti ras, gender, atau usia, sehingga pemilihan fitur dalam model machine learning harus dilakukan dengan hati-hati agar tidak menghasilkan bias.

Untuk cakupan global, General Data Protection Regulation (GDPR) menetapkan prinsip penting seperti hak penghapusan data (*right to erasure*), portabilitas data, dasar hukum pemrosesan data. Di Indonesia, kepatuhan terhadap Peraturan OJK tentang Layanan Pinjam Meminjam Uang Berbasis Teknologi Informasi juga menjadi acuan utama, khususnya dalam aspek perlindungan konsumen dan tata kelola data. Dengan demikian, sistem yang dirancang tidak hanya berfokus pada performa, tetapi juga memastikan bahwa seluruh proses pengolahan data dapat dipertanggungjawabkan secara hukum dan etika.

3.3. Data Privacy

Perlindungan privasi data peminjam diimplementasikan melalui berbagai mekanisme sejak tahap awal pipeline. Teknik anonimisasi dan pseudonimisasi diterapkan untuk menghilangkan atau menggantikan informasi yang dapat mengidentifikasi individu secara langsung (Personally Identifiable Information / PII), seperti nama, nomor identitas, dan alamat lengkap. Dataset Lending Club yang digunakan juga telah menerapkan perlindungan bawaan, misalnya dengan hanya menampilkan kode pos dalam format parsial (contoh: 481xx).

Selain itu, diterapkan prinsip data minimization, di mana hanya 26 dari 151 kolom yang digunakan dalam proses analisis. Kolom yang tidak relevan atau berpotensi mengandung data sensitif tidak disertakan dalam pipeline. Kebijakan data retention juga diterapkan untuk memastikan bahwa data tidak disimpan lebih lama dari yang diperlukan. Data yang sudah tidak digunakan akan dihapus secara aman menggunakan teknik seperti *cryptographic erasure*, sehingga tidak dapat dipulihkan kembali. Pendekatan ini memastikan bahwa sistem tidak hanya aman, tetapi juga menghormati privasi pengguna secara menyeluruh.

3.4. Data Quality

Kualitas data merupakan fondasi utama dalam membangun sistem analitik yang andal. Analisis terhadap dataset Lending Club mengidentifikasi beberapa permasalahan utama yang perlu ditangani sebelum data dapat digunakan untuk pemodelan.

Permasalahan pertama adalah keberadaan outliers ekstrem. Pada kolom Debt-To-Income (DTI) dataset rejected, ditemukan nilai tidak wajar hingga 1.690.800% dan nilai negatif. Sekitar 11,96% data berada di luar rentang normal (0–100%). Penanganan dilakukan menggunakan:

- Clipping untuk membatasi nilai dalam rentang wajar
- Winsorization (persentil 99) untuk variabel seperti pendapatan

Permasalahan kedua adalah missing values pada beberapa kolom penting, seperti Risk Score dan Employment Length. Strategi yang digunakan meliputi:

- Imputasi median untuk data numerik
- Imputasi kategori "Unknown" untuk data kategorikal

Permasalahan ketiga adalah inkonsistensi format data. Contohnya:

- DTI dalam format string ("10%") perlu dikonversi ke numerik
- emp_length perlu diubah ke representasi numerik
- issue_d perlu diekstrak menjadi fitur waktu (tahun dan bulan)

Permasalahan keempat adalah perbedaan skema antar dataset (accepted vs rejected), yang mencerminkan kompleksitas data pada lingkungan Big Data. Hal ini memerlukan perhatian khusus dalam analisis agar tidak menghasilkan interpretasi yang keliru.

Untuk mengatasi seluruh permasalahan tersebut, dikembangkan pipeline data cleaning yang terstruktur dan reproducible, mencakup:

1. Handling missing values
2. Handling outliers
3. Data type conversion
4. Feature engineering
5. Data validation

Pipeline ini diimplementasikan dalam bentuk skrip Python yang terdokumentasi, sehingga seluruh proses dapat direproduksi secara konsisten kapan pun diperlukan.

BAB IV

DATA

4.1. Deskripsi Data

Dataset yang digunakan dalam studi ini adalah Lending Club Loan Data periode 2007–2018 yang tersedia secara publik melalui Kaggle (lisensi CC0-1.0). Dataset ini terdiri dari dua subset utama yang merepresentasikan dua tahap berbeda dalam proses pemberian kredit pada platform P2P lending, yaitu data pinjaman yang disetujui (*accepted loans*) dan data aplikasi yang ditolak (*rejected loans*).

Subset pertama, yaitu *accepted loans*, memuat 2.260.701 baris data dengan 151 atribut dalam format CSV terkompresi (375 MB). Dataset ini mencakup informasi komprehensif terkait pinjaman, meliputi karakteristik pinjaman (jumlah pinjaman, suku bunga, tenor, grade risiko), profil peminjam (pendapatan tahunan, lama bekerja, kepemilikan rumah, lokasi), riwayat kredit (skor FICO, Debt-to-Income/DTI, histori keterlambatan, utilisasi kredit), hingga status akhir pinjaman. Untuk efisiensi pemrosesan, dilakukan seleksi terhadap 26 atribut yang paling relevan, dengan konsumsi memori sebesar $\pm 1,76$ GB.

Subset kedua, yaitu *rejected loans*, memuat 27.648.741 baris data dengan hanya 9 atribut (244 MB). Perbedaan jumlah kolom yang signifikan (151 vs 9) menunjukkan bahwa proses penolakan terjadi pada tahap awal (*early screening*), sebelum data lengkap peminjam dikumpulkan. Variabel yang tersedia antara lain jumlah pinjaman yang diajukan, skor risiko, DTI, lama bekerja, lokasi, dan informasi dasar lainnya. Tabel 4.1 menyajikan statistik deskriptif variabel numerik utama pada dataset *accepted* setelah penanganan outlier:

Tabel 4.1. Statistik Deskriptif Variabel Numerik pada Dataset Accepted Loans

Variabel	Mean	Std	Min	Median	Maks
Loan Amount (USD)	15.047	9.190	500	12.900	40.000
Interest Rate (%)	13,09	4,83	5,31	12,62	30,99
Annual Income (USD)*	76.163	44.612	0	65.000	270.000
DTI (%)*	18,66	9,69	0	17,84	100
FICO Score	698,59	33,01	610	690	845
Credit Utilization (%)	50,34	24,71	0	50,30	100

* setelah penanganan outlier ekstrem

Distribusi status pinjaman di tabel 4.1 menunjukkan bahwa:

- 47,63% berstatus Fully Paid
- 38,85% berstatus Current
- 11,88% berstatus Charged Off
- sisanya berada pada status Late, Default, dan lainnya

Untuk keperluan pemodelan, dibentuk label biner `is_default`, yang mencakup status bermasalah. Hasilnya menunjukkan bahwa terdapat 294.415 kasus default atau 13,02% dari total pinjaman.

Analisis tren tahunan menunjukkan pertumbuhan industri yang sangat signifikan, dari 603 pinjaman (USD 4,79 juta) pada tahun 2007 menjadi 495.242 pinjaman (USD 7,94 miliar) pada tahun 2018. Tingkat gagal bayar mencapai puncaknya pada tahun 2015 sebesar 18,39% dan menurun pada tahun-tahun berikutnya. Namun, penurunan ini perlu diinterpretasikan dengan hati hati karena adanya survivorship bias, di mana pinjaman pada tahun-tahun terakhir belum sepenuhnya jatuh tempo. Analisis berdasarkan grade pinjaman menunjukkan hubungan yang konsisten antara risiko dan suku bunga:

Tabel 4.2. Distribusi Risiko Pinjaman Berdasarkan Grade

Grade	Default Rate	Avg Interest	Avg FICO
A	3,66%	7,08%	729
B	8,79%	10,68%	700
C	14,57%	14,14%	689
D	20,59%	18,14%	684
E	28,46%	21,83%	682
F	36,51%	25,45%	680
G	39,74%	28,07%	679

Melalui Tabel 4.2 terlihat bahwa semakin rendah grade, semakin tinggi tingkat gagal bayar. Namun, perbedaan skor FICO antar grade (khususnya C–G) relatif kecil, sehingga menunjukkan bahwa penentuan risiko tidak hanya bergantung pada satu variabel, melainkan kombinasi berbagai faktor. Analisis komparatif antara dataset *accepted* dan *rejected* menunjukkan:

- Rata-rata skor kredit *accepted* ≈ 699 , *rejected* ≈ 628

- Terdapat lebih dari 30.000 peminjam dengan skor tinggi tetap ditolak
- DTI accepted (18,66%) lebih rendah dibanding rejected (26,58%)

Temuan ini menunjukkan bahwa keputusan kredit bersifat multifaktor dan tidak linear.

Hasil analisis korelasi Pearson menunjukkan bahwa:

- Fitur dengan korelasi positif tertinggi: interest rate ($r = 0,2089$)
- Fitur dengan korelasi negatif tertinggi: FICO ($r = -0,1211$)

Nilai korelasi yang relatif rendah mengindikasikan bahwa hubungan antara fitur dan risiko default bersifat kompleks dan tidak linear, sehingga pendekatan machine learning menjadi lebih relevan dibandingkan metode statistik sederhana.


4.2. Model Data

Model data yang digunakan dalam studi ini berbasis flat-file tabular model, yaitu representasi data dalam bentuk tabel di mana setiap baris merepresentasikan satu record pinjaman dan setiap kolom merepresentasikan atribut. Pendekatan ini bersifat denormalized (wide table), di mana seluruh informasi terkait pinjaman disimpan dalam satu baris tanpa relasi antar tabel. Keuntungan utama pendekatan ini adalah efisiensi dalam analisis dan machine learning karena tidak memerlukan operasi join yang kompleks. Karakteristik dataset dirangkum pada tabel 4.3 berikut

Tabel 4.3. Perbandingan Karakteristik Dataset Accepted dan Rejected

Atribut	Accepted	Rejected
Jumlah kolom (original)	151	9
Jumlah kolom (digunakan)	26	9
Jumlah baris	2.260.701	27.648.741
Format file	CSV (.csv.gz)	CSV (.csv.gz)
Target variabel	is_default	—

Perbedaan struktur antar dataset mencerminkan karakteristik variety dalam Big Data, di mana data dari sumber yang sama dapat memiliki skema yang berbeda. Dalam pipeline pemrosesan, data mengalami transformasi bertahap sebagai berikut:



Gambar 4.1. Pipeline Transformasi Data dari Raw Data hingga Input Machine Learning

Gambar 4.1 menunjukkan pipeline transformasi data yang digunakan dalam penelitian ini. Pipeline ini menggambarkan alur perubahan representasi data dari bentuk mentah hingga siap digunakan sebagai input model machine learning. Proses transformasi data terdiri dari empat tahap utama, yaitu:

1. Raw Data (CSV - Data Lake Layer)

Tahap awal merupakan penyimpanan data mentah dalam format CSV terkompresi (.csv.gz). Data pada tahap ini berfungsi sebagai *source of truth* yang tidak mengalami modifikasi. Penyimpanan dalam format asli memungkinkan proses audit, pelacakan data (*data lineage*), serta reprocessing apabila diperlukan di kemudian hari.

2. Data Processing (Pandas DataFrame)

Data mentah kemudian dimuat ke dalam Pandas DataFrame menggunakan teknik chunking untuk mengatasi keterbatasan memori. Pada tahap ini dilakukan seluruh proses transformasi utama, meliputi:

- Pembersihan data (*data cleaning*)
- Penanganan missing values dan outlier
- Rekayasa fitur (*feature engineering*)

- Eksplorasi data (*EDA*)

DataFrame berperan sebagai struktur data utama yang fleksibel untuk manipulasi dan analisis.

3. Intermediate Storage (Apache Parquet)

Setelah proses pembersihan dan transformasi selesai, data disimpan dalam format Apache Parquet. Format ini dipilih karena memiliki efisiensi kompresi yang tinggi serta mendukung pembacaan kolumnar (*columnar read*), sehingga hanya kolom yang diperlukan yang dibaca saat proses analitik. Penyimpanan ini juga memungkinkan reuse data tanpa perlu mengulang proses cleaning yang memakan waktu.

4. Machine Learning Input (NumPy Array)

Pada tahap akhir, data yang telah diproses dikonversi menjadi format NumPy array sebagai input model machine learning. Transformasi ini mencakup encoding variabel kategorikal, normalisasi fitur numerik, serta pembentukan matriks fitur (*X*) dan target (*y*). Format NumPy dipilih karena kompatibel dengan berbagai algoritma dalam ekosistem Scikit-learn dan memungkinkan komputasi yang lebih efisien.

Pipeline ini menunjukkan bahwa setiap representasi data digunakan sesuai dengan tujuannya masing-masing:

- CSV = Penyimpanan mentah dan portabilitas
- DataFrame = Fleksibilitas manipulasi data
- Parquet = Efisiensi penyimpanan dan akses ulang
- NumPy = Kompatibilitas dengan model machine learning

Dengan pendekatan bertahap ini, sistem tidak hanya efisien secara komputasi, tetapi juga terstruktur dan mudah direproduksi.

4.3. Dataset untuk Diolah Menggunakan Machine Learning

Setelah dilakukan eksplorasi terhadap kedua subset pada Lending Club Loan Data, yaitu *accepted loans* dan *rejected loans*, dipilih dataset **accepted loans** sebagai dataset utama

untuk proses machine learning. Pemilihan ini didasarkan pada beberapa pertimbangan teknis dan bisnis. Dataset accepted loans memiliki variabel target yang dapat digunakan untuk supervised learning, yaitu loan_status, sehingga memungkinkan pembentukan label biner is_default. Sebaliknya, dataset rejected loans tidak memiliki outcome pembayaran karena aplikasi pinjaman telah ditolak sebelum proses kredit berlangsung. Akibatnya, dataset rejected loans tidak dapat digunakan secara langsung untuk membangun model prediksi gagal bayar. Selain memiliki target variable yang jelas, dataset accepted loans juga menyediakan informasi yang lebih lengkap dibandingkan rejected loans. Dataset ini terdiri dari 151 atribut yang mencakup karakteristik pinjaman, profil peminjam, histori kredit, hingga metadata transaksi. Kelengkapan atribut tersebut memberikan ruang yang luas untuk proses feature engineering dan eksplorasi variabel prediktor. Sementara itu, dataset rejected loans hanya memiliki 9 atribut sehingga informasi yang tersedia relatif terbatas dan kurang memadai untuk membangun model machine learning yang komprehensif.

Dari sisi bisnis, penggunaan accepted loans lebih relevan dengan tujuan penelitian, yaitu membangun sistem prediksi risiko gagal bayar pada platform P2P lending. Model yang dihasilkan diharapkan mampu membantu proses pengambilan keputusan kredit secara lebih akurat dan adaptif. Walaupun tidak digunakan sebagai dataset utama machine learning, dataset rejected loans tetap dimanfaatkan pada tahap graph analytics untuk membantu menganalisis pola hubungan antara peminjam yang diterima dan ditolak. Pendekatan ini sejalan dengan konsep Big Data yang memanfaatkan seluruh data yang tersedia sebagai sumber insight. Dari total 151 kolom pada dataset accepted loans, dilakukan proses seleksi fitur untuk memilih atribut yang paling relevan terhadap prediksi default. Proses seleksi fitur bertujuan untuk mengurangi kompleksitas data, mempercepat proses komputasi, menghemat penggunaan memori, serta menghindari penggunaan fitur yang redundan atau tidak relevan. Selain itu, proses ini juga mendukung prinsip *data minimization* pada tata kelola data yang telah dibahas pada Bab 3.

Fitur-fitur yang dipilih terdiri dari kombinasi fitur numerik dan kategorikal. Fitur numerik meliputi loan_amnt, funded_amnt, installment, int_rate, annual_inc, dti, fico_range_low, fico_range_high, open_acc, pub_rec, revol_bal, revol_util, total_acc, term_months, emp_length_num, issue_year, dan issue_month. Selain fitur asli, ditambahkan beberapa fitur hasil feature engineering seperti fico_avg, credit_utilization, loan_to_income, installment_to_income,

dan `total_risk_indicators`. Untuk fitur kategorikal digunakan atribut `grade`, `sub_grade`, `home_ownership`, `verification_status`, `purpose`, `addr_state`, dan `application_type`. Proses pengurangan dari 151 kolom menjadi 26 fitur utama menunjukkan penerapan strategi *column pruning* dalam pengolahan Big Data. Pendekatan ini membantu meningkatkan efisiensi pemrosesan tanpa mengurangi kualitas informasi yang dibutuhkan model. Dengan jumlah fitur yang lebih terfokus, proses training model menjadi lebih ringan dan scalable untuk lingkungan Big Data.

Pembagian data dilakukan menggunakan pendekatan *time-based split* untuk menghindari terjadinya *data leakage*. Pendekatan ini dipilih karena dalam implementasi nyata, model credit scoring digunakan untuk memprediksi pinjaman pada periode mendatang berdasarkan data historis. Oleh karena itu, data pelatihan harus berasal dari periode yang lebih lama dibandingkan data pengujian. Pada penelitian ini, data periode 2007–2016 digunakan sebagai training set dengan total 1.321.880 record, sedangkan data periode 2017–2018 digunakan sebagai test set dengan total 938.821 record. Pendekatan ini menghasilkan evaluasi model yang lebih realistis karena model diuji menggunakan data masa depan yang belum pernah dilihat sebelumnya selama proses training.

Selanjutnya, training set dibagi kembali menjadi training dan validation set menggunakan stratified split agar distribusi kelas tetap terjaga. Karena data default bersifat imbalanced, dilakukan teknik *random undersampling* pada kelas mayoritas (*non-default*) di training set. Teknik ini bertujuan agar model dapat belajar mengenali pola default dengan lebih baik dan tidak bias terhadap kelas mayoritas. Hasil akhir pembagian data menghasilkan training set sebanyak 387.688 record dalam kondisi balanced, validation set sebanyak 68.416 record, dan test set sebanyak 938.821 record dengan distribusi asli yang tetap imbalanced. Pendekatan ini memungkinkan model dilatih menggunakan data yang seimbang, namun tetap dievaluasi menggunakan distribusi data yang realistis sesuai kondisi dunia nyata.

BAB V

Machine Learning untuk Big Data

5.1. Data Preprocessing

Tahap data preprocessing dilakukan untuk memastikan bahwa dataset berada dalam kondisi yang optimal sebelum digunakan dalam proses machine learning. Mengingat dataset Lending Club memiliki skala yang besar, variasi format data yang beragam, serta berbagai permasalahan kualitas data seperti missing values dan outlier, maka preprocessing menjadi tahapan yang sangat penting dalam pipeline analitik. Langkah pertama yang dilakukan adalah transformasi variabel target. Kolom `loan_status` yang bersifat kategorikal diubah menjadi label biner `is_default`. Status seperti *Charged Off*, *Default*, *Late (31-120 days)*, dan *Late (16-30 days)* dikategorikan sebagai default (1), sedangkan status lainnya seperti *Fully Paid*, *Current*, dan *In Grace Period* dikategorikan sebagai non-default (0). Transformasi ini menghasilkan sekitar 13,02% kasus default dari total pinjaman yang disetujui.

Selanjutnya dilakukan konversi tipe data pada beberapa atribut yang masih berada dalam format string. Kolom `term` yang memiliki format seperti “36 months” dan “60 months” diekstrak menjadi variabel numerik `term_months`. Kolom `int_rate` dan `revol_util` yang mengandung simbol persen (%) dikonversi menjadi tipe float agar dapat digunakan dalam proses komputasi numerik. Selain itu, kolom `issue_d` diekstrak menjadi `issue_year` dan `issue_month` untuk menangkap pola temporal dalam perilaku pinjaman dari waktu ke waktu. Tahap berikutnya adalah penanganan missing values. Untuk fitur numerik, nilai kosong diimputasi menggunakan median karena lebih robust terhadap outlier dibandingkan mean. Sementara itu, fitur kategorikal diimputasi menggunakan label “Unknown” agar informasi keberadaan data yang hilang tetap dipertahankan tanpa harus menghapus record. Pendekatan ini dipilih untuk menjaga jumlah data tetap besar dan representatif dalam konteks Big Data.

Dataset juga memiliki beberapa outlier ekstrem, terutama pada fitur seperti `annual_inc`, `dti`, dan `revol_util`. Oleh karena itu dilakukan teknik clipping dan winsorization untuk membatasi nilai pada rentang yang lebih realistis. Nilai DTI dan `revol_util` dibatasi pada rentang 0–100%, sedangkan annual income dibatasi hingga persentil ke-99 untuk mengurangi pengaruh nilai

ekstrem terhadap proses training model. Pendekatan ini membantu meningkatkan stabilitas model dan mengurangi distorsi statistik.

grade, sub_grade, home_ownership, verification_status, purpose, addr_state dan application_type merupakan *categorical features*, dilakukan proses label encoding agar seluruh fitur dapat direpresentasikan dalam bentuk numerik. Teknik ini dipilih karena seluruh algoritma machine learning yang digunakan memerlukan input numerik untuk proses training. Tahap terakhir adalah normalisasi fitur numerik menggunakan StandardScaler. Proses ini dilakukan karena beberapa fitur memiliki skala yang sangat berbeda, misalnya loan_amnt yang bernilai ribuan dolar dan int_rate yang hanya berada pada rentang puluhan persen. Standardisasi membantu model machine learning, khususnya model linear seperti Logistic Regression, agar tidak bias terhadap fitur dengan skala lebih besar. Proses fitting scaler hanya dilakukan pada training set, kemudian scaler yang sama diterapkan pada validation dan test set untuk menghindari data leakage. Melalui seluruh tahapan preprocessing tersebut, dataset berhasil ditransformasikan menjadi representasi data yang lebih bersih, konsisten, dan siap digunakan pada tahap feature engineering serta pengembangan model machine learning.

5.2. Feature Engineering

Feature engineering dilakukan untuk meningkatkan kualitas representasi data sebelum digunakan dalam proses machine learning. Pada tahap ini, beberapa fitur baru dibentuk berdasarkan kombinasi dan transformasi dari fitur asli agar model dapat menangkap pola risiko kredit dengan lebih baik. Dalam konteks credit scoring, feature engineering menjadi penting karena banyak indikator risiko tidak dapat direpresentasikan secara optimal hanya menggunakan variabel mentah. Salah satu fitur turunan yang dikembangkan adalah fico_avg, yaitu rata-rata dari fico_range_low dan fico_range_high. Dataset Lending Club menyediakan skor FICO dalam bentuk rentang sehingga penggunaan nilai rata-rata dianggap lebih representatif untuk menggambarkan kualitas kredit peminjam secara keseluruhan. Fitur ini digunakan sebagai indikator utama kemampuan bayar peminjam dan memiliki hubungan negatif terhadap probabilitas default.

Fitur berikutnya adalah credit_utilization, yang dihitung berdasarkan proporsi saldo kredit berputar (revol_bal) terhadap total utilisasi kredit. Fitur ini digunakan untuk menggambarkan

tingkat penggunaan kredit aktif oleh peminjam. Semakin tinggi utilisasi kredit, semakin besar kemungkinan peminjam mengalami tekanan finansial dan kesulitan pembayaran. Oleh karena itu, fitur ini menjadi salah satu indikator penting dalam analisis risiko kredit. Selain itu, dikembangkan fitur `loan_to_income`, yaitu rasio antara jumlah pinjaman (`loan_amnt`) terhadap pendapatan tahunan (`annual_inc`). Rasio ini digunakan untuk mengukur beban pinjaman relatif terhadap kemampuan finansial peminjam. Semakin besar nilai rasio tersebut, semakin tinggi risiko bahwa peminjam akan mengalami kesulitan dalam melunasi pinjaman.

Untuk menangkap kemampuan pembayaran bulanan secara lebih spesifik, dibentuk fitur `installment_to_income`, yaitu rasio antara cicilan bulanan (`installment`) terhadap estimasi pendapatan bulanan. Fitur ini dianggap lebih representatif dalam menggambarkan *affordability* dibandingkan hanya melihat jumlah pinjaman secara keseluruhan, karena berhubungan langsung dengan beban pembayaran yang harus ditanggung setiap bulan. Feature engineering juga dilakukan pada indikator histori kredit melalui fitur `total_risk_indicators`, yang merupakan kombinasi antara jumlah catatan kredit bermasalah (`pub_rec`) dan jumlah keterlambatan pembayaran dalam dua tahun terakhir (`delinq_2yrs`). Fitur ini digunakan untuk memberikan gambaran agregat mengenai perilaku kredit historis peminjam.

Selain fitur berbasis finansial, dilakukan pula ekstraksi fitur temporal dari `issue_d` menjadi `issue_year` dan `issue_month`. Penambahan fitur waktu ini bertujuan untuk menangkap kemungkinan perubahan pola default akibat kondisi ekonomi, perubahan kebijakan platform, maupun dinamika pasar kredit dari tahun ke tahun. Secara keseluruhan, proses feature engineering menghasilkan sejumlah fitur baru yang membantu meningkatkan kualitas sinyal prediktif dalam model machine learning. Kombinasi antara fitur asli dan fitur turunan memungkinkan model memahami hubungan risiko kredit secara lebih komprehensif dibandingkan hanya menggunakan atribut mentah dari dataset awal.

5.3. Algoritma *Machine Learning*

Pemilihan algoritma machine learning pada penelitian ini dilakukan dengan mempertimbangkan karakteristik permasalahan, ukuran dataset, serta kebutuhan skalabilitas dalam lingkungan Big Data. Permasalahan prediksi risiko gagal bayar termasuk ke dalam supervised learning dengan tipe binary classification, sehingga algoritma yang digunakan harus

mampu memprediksi dua kelas, yaitu default dan non-default. Pada implementasi tanpa Spark MLlib, digunakan tiga algoritma utama yaitu Logistic Regression, Random Forest, dan XGBoost. Ketiga algoritma ini dipilih karena memiliki karakteristik yang berbeda sehingga dapat digunakan untuk membandingkan performa model linear dan model ensemble berbasis tree.

Logistic Regression digunakan sebagai baseline model karena memiliki struktur yang sederhana, mudah diinterpretasikan, serta efisien secara komputasi. Model ini bekerja dengan memprediksi probabilitas suatu pinjaman mengalami default berdasarkan kombinasi linear dari seluruh fitur input. Selain cepat dalam proses training, Logistic Regression juga umum digunakan dalam industri credit scoring karena interpretabilitasnya yang tinggi. Random Forest dipilih karena mampu menangkap hubungan non-linear antar fitur dan lebih robust terhadap overfitting dibandingkan decision tree tunggal. Algoritma ini bekerja menggunakan pendekatan ensemble berbasis bagging dengan membangun banyak decision tree secara paralel, kemudian menggabungkan hasil prediksi melalui voting. Random Forest juga mampu menangani data dengan kompleksitas tinggi tanpa memerlukan asumsi distribusi tertentu pada data.

Selain Random Forest, digunakan pula XGBoost sebagai model boosting berbasis gradient boosting trees. XGBoost dipilih karena dikenal memiliki performa tinggi pada data tabular dan mampu menghasilkan akurasi yang lebih baik dibandingkan model linear maupun ensemble konvensional. Algoritma ini bekerja secara sequential, di mana setiap tree baru dibangun untuk memperbaiki kesalahan prediksi dari tree sebelumnya. Selain itu, XGBoost memiliki mekanisme regularization bawaan yang membantu mengurangi risiko overfitting. Untuk implementasi berbasis Big Data, dilakukan pula pengembangan model menggunakan Apache Spark MLlib. Pendekatan ini bertujuan untuk mengevaluasi kemampuan pemrosesan distributed computing pada dataset berskala besar. Algoritma yang digunakan pada Spark MLlib meliputi Logistic Regression, RandomForestClassifier, dan GBClassifier.

Spark Logistic Regression digunakan untuk membandingkan implementasi linear model pada lingkungan distributed dengan implementasi scikit-learn. Sementara itu, RandomForestClassifier dan GBClassifier digunakan untuk mengevaluasi performa model ensemble pada arsitektur Spark. GBClassifier pada Spark MLlib memiliki konsep yang serupa dengan gradient boosting pada XGBoost, namun diimplementasikan menggunakan framework distributed computing milik Spark. Penggunaan dua pendekatan berbeda, yaitu scikit-learn dan

Spark MLlib, memberikan gambaran mengenai trade-off antara kemudahan pengembangan model pada single-machine environment dan kemampuan skalabilitas pada distributed environment. Pendekatan ini juga memungkinkan evaluasi yang lebih komprehensif terhadap performa model machine learning dalam konteks Big Data Analytics.

5.4. Proses Pengembangan Model dengan dan tanpa Spark MLlib

Proses pengembangan model dilakukan menggunakan dua pendekatan utama, yaitu implementasi machine learning berbasis scikit-learn pada lingkungan single-machine dan implementasi berbasis Apache Spark MLlib pada lingkungan distributed computing. Kedua pendekatan ini digunakan untuk membandingkan performa model sekaligus mengevaluasi skalabilitas pemrosesan dalam konteks Big Data. Pada implementasi tanpa Spark, proses pengembangan model dilakukan menggunakan library scikit-learn dan XGBoost. Dataset hasil preprocessing dan feature engineering dikonversi ke dalam bentuk matriks fitur (X) dan target (y) menggunakan format NumPy array. Selanjutnya, training set dibagi kembali menjadi training dan validation set menggunakan stratified split agar distribusi kelas tetap seimbang selama proses pelatihan model.

Model pertama yang dikembangkan adalah Logistic Regression sebagai baseline model. Model ini dilatih menggunakan fitur yang telah melalui proses standardisasi dengan StandardScaler. Parameter `class_weight='balanced'` digunakan untuk membantu model menangani ketidakseimbangan kelas pada data default. Model berikutnya adalah Random Forest yang dikembangkan menggunakan pendekatan ensemble berbasis bagging. Pada implementasinya digunakan sejumlah decision tree yang dilatih secara paralel dengan subset data yang berbeda. Pendekatan ini membantu meningkatkan stabilitas prediksi dan mengurangi risiko overfitting dibandingkan decision tree tunggal.

Selain Random Forest, dikembangkan pula model XGBoost sebagai algoritma boosting utama dalam penelitian ini. Model ini menggunakan pendekatan sequential boosting, di mana setiap tree baru dibangun untuk memperbaiki kesalahan dari ensemble sebelumnya. Penggunaan XGBoost dipilih karena kemampuannya dalam menangani hubungan non-linear yang kompleks serta performanya yang tinggi pada data tabular berskala besar. Untuk implementasi berbasis Big Data, dilakukan pengembangan model menggunakan Apache Spark MLlib melalui PySpark.

Spark session dikonfigurasi menggunakan mode local single-node pada lingkungan Google Colaboratory. Walaupun tidak menggunakan cluster multi-node penuh, pendekatan ini tetap memberikan gambaran mengenai workflow distributed machine learning pada Spark.

Dataset yang sebelumnya berada dalam format pandas DataFrame dikonversi menjadi Spark DataFrame menggunakan `spark.createDataFrame()`. Selanjutnya dilakukan proses VectorAssembler untuk menggabungkan seluruh fitur menjadi satu kolom vector (features) yang digunakan sebagai input standar pada Spark MLlib. Model pertama yang dikembangkan pada Spark MLlib adalah Logistic Regression. Implementasi ini digunakan untuk membandingkan performa model linear antara scikit-learn dan Spark MLlib. Selanjutnya digunakan RandomForestClassifier sebagai implementasi distributed random forest pada Spark. Selain itu, digunakan pula GBTClassifier sebagai implementasi gradient boosting pada Spark MLlib.


Secara umum, implementasi model pada scikit-learn menunjukkan proses training yang lebih cepat dibandingkan Spark MLlib pada lingkungan single-node. Hal ini disebabkan oleh overhead distributed computing pada Spark yang belum memberikan keuntungan signifikan ketika dijalankan pada satu mesin. Sebaliknya, Spark MLlib dirancang untuk skenario dengan data dan infrastruktur yang jauh lebih besar, sehingga keunggulan utamanya terletak pada kemampuan scalability horizontal ketika dijalankan pada cluster multi-node. Walaupun performa training scikit-learn lebih efisien pada skala penelitian ini, implementasi Spark MLlib tetap penting karena menunjukkan kesiapan pipeline untuk dikembangkan pada lingkungan Big Data yang lebih besar di masa mendatang. Pendekatan ini juga memperlihatkan bagaimana proses machine learning dapat diintegrasikan dengan ekosistem distributed computing seperti Apache Spark.

5.5. Evaluasi Model

Evaluasi model dilakukan untuk mengukur kemampuan masing-masing algoritma dalam memprediksi risiko gagal bayar pada data pinjaman. Karena permasalahan credit scoring memiliki distribusi kelas yang tidak seimbang, penggunaan accuracy saja tidak cukup untuk menggambarkan kualitas model secara menyeluruh. Oleh karena itu, evaluasi dilakukan menggunakan beberapa metrik klasifikasi, yaitu Accuracy, Precision, Recall, F1-Score, dan AUC-ROC. AUC-ROC digunakan sebagai metrik utama karena mampu mengukur kemampuan model dalam membedakan kelas default dan non-default secara keseluruhan tanpa bergantung pada

threshold tertentu. Selain itu, F1-Score digunakan untuk mengevaluasi keseimbangan antara precision dan recall, terutama karena data default memiliki proporsi yang jauh lebih kecil dibandingkan non-default.


Hasil evaluasi menunjukkan bahwa model berbasis ensemble menghasilkan performa yang lebih baik dibandingkan model linear. XGBoost menjadi model dengan performa terbaik dengan nilai AUC-ROC sekitar 0,71, diikuti oleh Random Forest dan Logistic Regression. Hasil ini menunjukkan bahwa pendekatan boosting mampu menangkap hubungan non-linear antar fitur dengan lebih baik dibandingkan model linear sederhana. Pada implementasi Spark MLlib, performa model secara umum sedikit lebih rendah dibandingkan implementasi scikit-learn. Meskipun demikian, Spark MLlib tetap menunjukkan kemampuan yang baik dalam memproses dataset berskala besar melalui pendekatan distributed computing. Perbedaan performa ini dipengaruhi oleh konfigurasi Spark yang dijalankan pada lingkungan single-node serta keterbatasan proses hyperparameter tuning pada implementasi distributed. Gambar berikut menunjukkan perbandingan performa seluruh model berdasarkan nilai AUC-ROC, F1-Score, dan waktu pelatihan.



Gambar 5.1 Perbandingan Performa Model Machine Learning Berdasarkan AUC-ROC, F1-Score, dan Waktu Pelatihan


Selain membandingkan performa antar model, dilakukan pula analisis confusion matrix pada model terbaik untuk melihat distribusi prediksi secara lebih detail. Confusion matrix menunjukkan jumlah prediksi benar dan salah untuk masing-masing kelas, yaitu true positive, true negative, false positive, dan false negative. Hasil confusion matrix menunjukkan bahwa model

mampu mengidentifikasi sebagian besar kasus non-default dengan baik, namun masih menghasilkan sejumlah false positive yang cukup besar. Kondisi ini umum terjadi pada kasus credit scoring karena model cenderung lebih konservatif dalam mendeteksi risiko gagal bayar.




Gambar 5.2 Confusion Matrix Model XGBoost pada Test Set

Selanjutnya dilakukan analisis feature importance untuk mengetahui fitur-fitur yang paling berpengaruh terhadap prediksi default. Hasil menunjukkan bahwa fitur seperti `sub_grade`, `grade`, `int_rate`, `dti`, dan `installment_to_income` menjadi faktor utama yang mempengaruhi keputusan model. Temuan ini konsisten dengan praktik industri credit scoring, di mana kualitas kredit dan kemampuan bayar menjadi indikator utama risiko pinjaman.



Gambar 5.3 Feature Importance pada Model XGBoost

Selain evaluasi berbasis threshold default sebesar 0,5, dilakukan pula proses threshold tuning untuk mencari threshold optimal berdasarkan keseimbangan precision dan recall. Pendekatan ini penting karena dalam konteks bisnis, biaya akibat false negative dan false positive tidak memiliki dampak yang sama. Pada credit scoring, kegagalan mendeteksi peminjam berisiko tinggi dapat menyebabkan kerugian finansial yang lebih besar dibandingkan menolak sebagian peminjam yang sebenarnya layak. Hasil threshold tuning menunjukkan bahwa perubahan threshold dapat meningkatkan nilai F1-Score dan membantu menyesuaikan model terhadap kebutuhan bisnis yang berbeda. Threshold yang lebih rendah meningkatkan recall, sedangkan threshold yang lebih tinggi meningkatkan precision.



Gambar 5.4 Threshold Tuning untuk Optimasi Precision dan Recall

Secara keseluruhan, hasil evaluasi menunjukkan bahwa model machine learning mampu memberikan performa yang cukup baik dalam memprediksi risiko gagal bayar pada platform P2P lending. Model berbasis ensemble, khususnya XGBoost, memberikan keseimbangan terbaik antara performa prediksi dan efisiensi komputasi pada dataset yang digunakan.

5.6. Analisis


Hasil evaluasi menunjukkan bahwa model berbasis ensemble memberikan performa yang lebih baik dibandingkan model linear dalam memprediksi risiko gagal bayar pada platform P2P lending. XGBoost menjadi model dengan performa terbaik berdasarkan nilai AUC-ROC dan F1-Score, yang menunjukkan bahwa pendekatan boosting lebih efektif dalam menangkap hubungan non-linear antar fitur dibandingkan Logistic Regression. Hal ini sejalan dengan karakteristik data credit scoring yang memiliki hubungan kompleks antara profil peminjam, histori kredit, dan risiko gagal bayar.

Performa Random Forest juga menunjukkan hasil yang cukup baik dan relatif stabil. Model ini mampu menangani variasi data serta mengurangi risiko overfitting melalui pendekatan ensemble berbasis bagging. Sementara itu, Logistic Regression tetap memberikan performa yang kompetitif meskipun lebih sederhana. Selain memiliki waktu pelatihan yang cepat, model linear ini juga memiliki interpretabilitas yang tinggi sehingga masih relevan digunakan pada sistem credit scoring yang membutuhkan transparansi keputusan.

Perbandingan antara implementasi scikit-learn dan Spark MLlib menunjukkan adanya trade-off antara performa dan skalabilitas. Pada penelitian ini, implementasi scikit-learn menghasilkan akurasi yang lebih baik dan waktu training yang lebih cepat dibandingkan Spark MLlib. Hal ini terjadi karena eksperimen dilakukan pada lingkungan single-node sehingga overhead distributed computing pada Spark belum memberikan keuntungan yang signifikan. Namun demikian, Spark MLlib tetap memiliki keunggulan dalam hal scalability karena dirancang untuk menangani data dengan ukuran yang jauh lebih besar pada lingkungan cluster multi-node.

Analisis feature importance menunjukkan bahwa fitur sub_grade, grade, dan int_rate memiliki pengaruh paling besar terhadap prediksi default. Temuan ini menunjukkan bahwa sistem penilaian risiko yang telah diterapkan oleh Lending Club sebenarnya sudah mengandung sinyal risiko yang kuat. Selain itu, fitur seperti dti dan installment_to_income juga memberikan kontribusi penting karena berkaitan langsung dengan kemampuan bayar peminjam. Hasil evaluasi juga memperlihatkan bahwa penggunaan threshold default sebesar 0,5 belum tentu menghasilkan keputusan bisnis yang optimal.

Pada konteks credit scoring, kesalahan dalam menyetujui peminjam berisiko tinggi memiliki dampak finansial yang lebih besar dibandingkan menolak sebagian peminjam yang sebenarnya layak. Oleh karena itu, threshold tuning menjadi langkah penting untuk menyesuaikan model terhadap kebutuhan bisnis dan tingkat toleransi risiko perusahaan. Untuk meningkatkan interpretabilitas model, dilakukan pula analisis menggunakan SHAP (*SHapley Additive exPlanations*). Pendekatan ini digunakan untuk memahami kontribusi masing-masing fitur terhadap prediksi model XGBoost. Hasil analisis menunjukkan bahwa kombinasi antara grade rendah, interest rate tinggi, utilisasi kredit tinggi, dan rasio cicilan terhadap pendapatan yang besar secara konsisten meningkatkan probabilitas default.



Gambar 5.5 SHAP Summary Plot pada Model XGBoost

Dari sisi bisnis, hasil penelitian menunjukkan bahwa pendekatan machine learning mampu membantu meningkatkan kualitas sistem credit scoring dibandingkan pendekatan tradisional berbasis satu indikator seperti FICO score. Model machine learning mampu mempertimbangkan kombinasi berbagai faktor secara simultan sehingga menghasilkan prediksi yang lebih adaptif dan granular. Secara keseluruhan, kombinasi antara preprocessing, feature engineering, model ensemble, dan evaluasi berbasis business-oriented metrics menunjukkan bahwa machine learning memiliki potensi yang kuat untuk diterapkan pada sistem analisis risiko kredit berbasis Big Data. Selain memberikan performa prediksi yang baik, pendekatan ini juga mendukung pengambilan keputusan yang lebih cepat, scalable, dan data-driven pada platform P2P lending.


BAB VI

Graph Analytics

6.1. Pengembangan *Graph*


Selain menggunakan pendekatan machine learning, penelitian ini juga memanfaatkan graph analytics untuk menganalisis hubungan antar fitur dan struktur risiko kredit pada dataset Lending Club. Pendekatan graph analytics digunakan karena mampu merepresentasikan hubungan antar entitas dalam bentuk node dan edge, sehingga pola keterkaitan antar variabel dapat diamati secara lebih intuitif dibandingkan analisis tabular konvensional. Graph pertama yang dikembangkan adalah *Feature Correlation Network*. Pada graph ini, setiap fitur numerik direpresentasikan sebagai node, sedangkan hubungan antar fitur direpresentasikan sebagai edge berdasarkan nilai korelasi Pearson. Edge dibentuk apabila pasangan fitur memiliki nilai korelasi absolut di atas threshold tertentu, sehingga hanya hubungan yang cukup signifikan yang divisualisasikan dalam graph.

Hasil visualisasi menunjukkan adanya beberapa kelompok fitur yang saling terhubung kuat. Fitur-fitur terkait skor kredit seperti `fico_range_low`, `fico_range_high`, dan `fico_avg` membentuk cluster tersendiri karena memiliki korelasi yang sangat tinggi. Selain itu, fitur `loan_amnt`, `funded_amnt`, dan `installment` juga menunjukkan hubungan yang erat karena seluruhnya berkaitan langsung dengan nilai pinjaman dan cicilan. Graph ini juga memperlihatkan hubungan negatif antara fitur seperti FICO score dan interest rate, di mana peminjam dengan skor kredit lebih tinggi cenderung memperoleh bunga pinjaman yang lebih rendah. Pola tersebut sesuai dengan prinsip risk-based pricing pada industri kredit.



Gambar 6.1 Feature Correlation Network pada Dataset Lending Club

Selain feature correlation network, dikembangkan pula graph berbasis grade risiko pinjaman (*Grade Risk Hierarchy*). Pada graph ini, setiap node merepresentasikan grade pinjaman dari A hingga G, sedangkan edge menunjukkan hubungan hierarki risiko antar grade. Semakin rendah kualitas grade, semakin tinggi tingkat risiko gagal bayar dan interest rate yang diberikan kepada peminjam. Visualisasi graph menunjukkan bahwa default rate meningkat secara konsisten dari grade A menuju grade G. Grade A memiliki tingkat default paling rendah dengan interest rate yang relatif kecil, sedangkan grade G memiliki tingkat default tertinggi dengan bunga pinjaman paling besar. Pola ini menunjukkan bahwa sistem grading Lending Club telah berhasil memisahkan kelompok risiko peminjam secara cukup baik. Meskipun demikian, perbedaan skor FICO antar grade tidak terlalu besar pada beberapa kategori menengah hingga tinggi risiko. Hal ini menunjukkan bahwa risiko kredit tidak hanya ditentukan oleh satu variabel saja, tetapi merupakan hasil kombinasi dari berbagai faktor seperti debt-to-income ratio, histori pembayaran, dan utilisasi kredit.



Gambar 6.2 Grade Risk Hierarchy Berdasarkan Tingkat Default dan Interest Rate

Pengembangan graph analytics pada penelitian ini memberikan pendekatan tambahan dalam memahami struktur data dan hubungan antar variabel pada sistem credit scoring. Pendekatan graph membantu mengidentifikasi pola korelasi, cluster fitur, serta struktur hierarki risiko yang tidak selalu terlihat secara langsung melalui model machine learning tradisional.

6.2. Analisis dan *Insight* yang Diperoleh

Hasil graph analytics memberikan beberapa insight penting yang melengkapi hasil machine learning pada Bab 5. Melalui pendekatan graph, hubungan antar fitur dan struktur risiko kredit dapat diamati secara lebih visual dan intuitif. Analisis ini membantu memahami bagaimana variabel-variabel pada sistem credit scoring saling berhubungan dan membentuk pola risiko tertentu. Pada feature correlation network terlihat bahwa beberapa fitur memiliki hubungan yang sangat kuat dan membentuk cluster tersendiri. Cluster pertama terdiri dari fitur-fitur terkait skor kredit seperti `fico_range_low`, `fico_range_high`, dan `fico_avg`. Hubungan yang sangat tinggi antar fitur tersebut menunjukkan adanya redundansi informasi, sehingga penggunaan salah satu representasi skor kredit sebenarnya sudah cukup untuk menggambarkan kualitas kredit peminjam.

Cluster lain terbentuk pada fitur-fitur terkait jumlah pinjaman dan cicilan seperti `loan_amnt`, `funded_amnt`, dan `installment`. Hubungan ini menunjukkan bahwa besarnya pinjaman secara langsung mempengaruhi beban cicilan yang harus dibayar peminjam. Selain itu, fitur `int_rate`, `grade`, dan `sub_grade` juga menunjukkan keterkaitan yang kuat, yang menandakan bahwa sistem penentuan bunga pada Lending Club memang sangat dipengaruhi oleh tingkat risiko peminjam. Analisis graph juga menunjukkan hubungan negatif antara skor FICO dan interest rate. Semakin tinggi skor kredit peminjam, semakin rendah bunga pinjaman yang diberikan. Temuan ini konsisten dengan konsep *risk-based pricing* pada industri keuangan, di mana peminjam dengan risiko lebih rendah memperoleh biaya pinjaman yang lebih murah.

Pada graph grade risk hierarchy terlihat bahwa peningkatan risiko gagal bayar terjadi secara bertahap dari grade A hingga grade G. Grade A memiliki tingkat default paling rendah dan rata-rata interest rate yang kecil, sedangkan grade G menunjukkan tingkat default tertinggi dengan bunga pinjaman paling besar. Struktur graph ini memperlihatkan bahwa sistem grading pada Lending Club telah mampu memetakan tingkat risiko peminjam secara cukup konsisten. Walaupun demikian, analisis juga menunjukkan bahwa perbedaan skor FICO antar beberapa grade tidak terlalu besar. Hal ini mengindikasikan bahwa risiko kredit tidak hanya ditentukan oleh satu faktor seperti skor kredit, tetapi merupakan kombinasi dari berbagai variabel lain seperti debt-to-income ratio, histori pembayaran, dan utilisasi kredit. Temuan ini mendukung hasil machine learning sebelumnya yang menunjukkan bahwa model ensemble berbasis banyak fitur mampu memberikan performa prediksi yang lebih baik dibandingkan pendekatan tradisional berbasis satu indikator.

Graph analytics juga membantu mengidentifikasi adanya fitur-fitur yang sangat dominan terhadap struktur risiko kredit, khususnya `grade`, `sub_grade`, dan `int_rate`. Ketiga fitur tersebut tidak hanya memiliki feature importance yang tinggi pada model machine learning, tetapi juga memiliki posisi sentral dalam struktur graph. Hal ini menunjukkan bahwa fitur-fitur tersebut merupakan representasi utama dari sinyal risiko kredit pada dataset Lending Club. Secara keseluruhan, kombinasi antara machine learning dan graph analytics memberikan pemahaman yang lebih komprehensif terhadap sistem credit scoring pada platform P2P lending. Machine learning berperan dalam menghasilkan prediksi risiko gagal bayar yang akurat, sedangkan graph analytics membantu menjelaskan hubungan struktural antar variabel dan pola risiko yang terbentuk

di dalam data. Pendekatan gabungan ini menunjukkan bahwa analisis Big Data tidak hanya berfokus pada prediksi, tetapi juga pada interpretasi dan pemahaman pola hubungan antar data secara lebih mendalam.